

2.1.1

Parent entropy:  $H(D) = -(\frac{3}{10} \log \frac{3}{10} + \frac{2}{10} \log \frac{2}{10} + \frac{3}{10} \log \frac{3}{10} + \frac{2}{10} \log \frac{2}{10}) = 1.97$

split by 天气: 晴朗  $H_1(D) = -(\frac{2}{5} \log \frac{2}{5} + \frac{1}{5} \log \frac{1}{5} + \frac{2}{5} \log \frac{2}{5}) = 1.52$

多云  $H_1(D_2) = -(\frac{1}{2} \log \frac{1}{2} + \frac{1}{2} \log \frac{1}{2}) = 1$

下雨  $H_1(D_3) = -(\frac{2}{3} \log \frac{2}{3}) = 0$

$|G_1 = H(D) - \frac{5}{10} H_1(D) - \frac{2}{10} H_1(D_2) - \frac{3}{10} H_1(D_3) = 1.97 - \frac{1}{2} \times 1.52 - \frac{1}{5} \times 1 - \frac{3}{10} \times 0 = 1.01$

split by 温度: 高  $H_2(D) = -(\frac{2}{3} \log \frac{2}{3} + \frac{1}{3} \log \frac{1}{3}) = 0.92$

中  $H_2(D_2) = -(\frac{2}{4} \log \frac{2}{4} + \frac{1}{4} \log \frac{1}{4} + \frac{1}{4} \log \frac{1}{4}) = 1.5$

低  $H_2(D_3) = -(\frac{2}{3} \log \frac{2}{3} + \frac{1}{3} \log \frac{1}{3}) = 0.92$

$|G_2 = H(D) - \frac{3}{10} H_2(D) - \frac{4}{10} H_2(D_2) - \frac{3}{10} H_2(D_3) = 1.97 - \frac{3}{10} \times 0.92 \times 2 - \frac{2}{5} \times 1.5 = 0.82$

split by 湿度: 低  $H_3(D) = -(\frac{2}{5} \log \frac{2}{5} + \frac{3}{5} \log \frac{3}{5}) = 0.97$

高  $H_3(D_2) = -(\frac{2}{5} \log \frac{2}{5} + \frac{3}{5} \log \frac{3}{5}) = 0.97$

$|G_3 = H(D) - \frac{5}{10} H_3(D) - \frac{5}{10} H_3(D_2) = 1.97 - \frac{1}{2} \times 2 \times 0.97 = 1$

split by 风力: 强  $H_4(D) = -(\frac{1}{3} \log \frac{1}{3} + \frac{1}{3} \log \frac{1}{3} + \frac{1}{3} \log \frac{1}{3}) = 1.58$

弱  $H_4(D_2) = -(\frac{2}{7} \log \frac{2}{7} + \frac{1}{7} \log \frac{1}{7} + \frac{1}{7} \log \frac{1}{7} + \frac{2}{7} \log \frac{2}{7}) = 1.84$

$|G_4 = H(D) - \frac{3}{10} H_4(D) - \frac{7}{10} H_4(D_2) = 1.97 - \frac{3}{10} \times 1.58 - \frac{7}{10} \times 1.84$

用天气作为根结点,划分信息增益最大  $= 0.21$

2.1.2

① 天气 下雨 → 看电影

② 天气 晴朗 → 逛商场 2

去野餐 2

去博物馆 1

split by 温度: 高  $H'_2(D) = -(\frac{1}{2} \log \frac{1}{2} + \frac{1}{2} \log \frac{1}{2}) = 1$

中  $H'_2(D_2) = -(\frac{1}{2} \log \frac{1}{2} + \frac{1}{2} \log \frac{1}{2}) = 1$

低  $H'_2(D_3) = -\log 1 = 0$

$|G'_2 = H_1(D) - \frac{2}{5} H'_2(D) - \frac{2}{5} H'_2(D_2) - \frac{1}{5} H'_2(D_3) = 1.52 - \frac{2}{5} \times 1 - \frac{2}{5} = 0.72$

split by 湿度: 低  $H'_3(D) = -(\frac{2}{4} \log \frac{2}{4} + \frac{2}{4} \log \frac{2}{4}) = 1$

高  $H'_3(D_2) = -\log 1 = 0$


$|G'_3 = H_1(D) - \frac{4}{5} H'_3(D) - \frac{1}{5} H'_3(D_2) = 1.52 - \frac{4}{5} \times 1 = 0.72$

split by 风力: 强  $H'_4(D) = -\log 1 = 0$

弱  $H'_4(D_2) = -(\frac{2}{4} \log \frac{2}{4} + \frac{1}{4} \log \frac{1}{4} + \frac{1}{4} \log \frac{1}{4}) = 1.5$

$|G'_4 = H_1(D) - \frac{1}{5} H'_4(D) - \frac{4}{5} H'_4(D_2) = 1.52 - \frac{4}{5} \times 1.5 = 0.32$

按湿度与温度分, 信息增益同样大, 我选湿度



晴朗低湿时:

split by 温度: 高  $H''_2(D) = -(\frac{1}{2} \log \frac{1}{2} + \frac{1}{2} \log \frac{1}{2}) = 1$

中  $H''_2(D_2) = -\log 1 = 0$

低  $H''_2(D_3) = -\log 1 = 0$

$|G_2'' = 1 - \frac{2}{4} \times 1 = 0.5$

$$H_{\psi}(D_2) = -\left(\frac{2}{3} \log \frac{2}{3} + \frac{1}{3} \log \frac{1}{3}\right) = 0.92$$

温度信息增益更大

晴朗 - 低湿  $\left\{ \begin{array}{l} \text{高温} \\ \text{中温} \\ \text{低温} \end{array} \right.$

湿度信息增益更大

1 玄统步  
 2 玄野管  
 玄野管  
 玄统步

最后按风区分

③天坛公园 → 1. 去散步  
1. 去博物馆

$$\text{高} \quad H_3'''(P_2) = -\log 1$$

split by 温度: 高  $H_2'''(Q) = -\log$

$$\phi \quad H_2^m(D_2) = -\log |$$
$$\text{低 } H_2^{III}(D_3) = 0$$

$$1G_2^{11} = 1 - 0 = 1$$

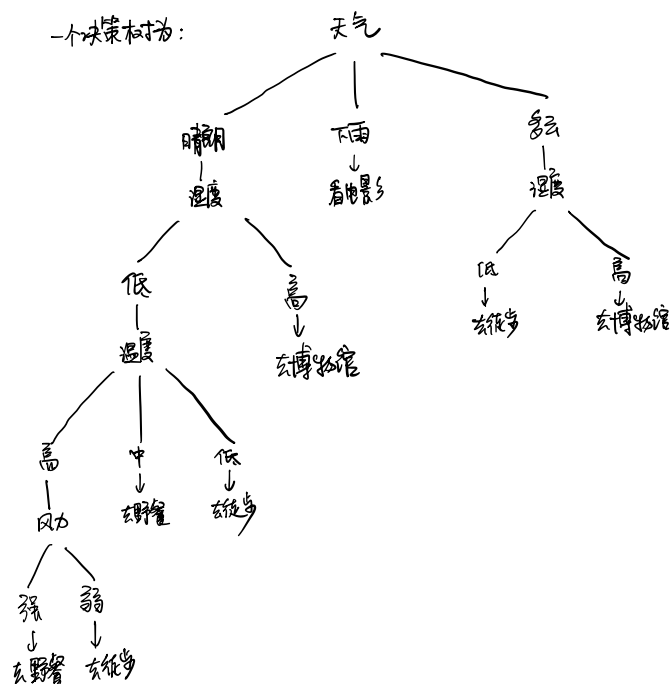
split by 熵: 熵:  $H_2^{(1)}(D) = -\log$

弱:  $H_4'''(D_2) = -\log |$

$$1G4'' = 1 - 0 = 1$$

三个 features 都可以用, 我选没

一个决策树为:



2.1.3 根据以上决策树,晴朗,高温,高湿,弱风 去博物馆

2.2.4 二分类问题我认为线性能力会更好一些,而回归树提供了清晰的决策边界。在这里,我发现树的深度对该问题影响不大。

2.3.1 | 蒙特卡罗估计样本均值  $\bar{x}$  的方差  $1 - (1 - \frac{1}{100})^{100}$

所有种子都被选中 的概率  $((1 - \frac{1}{100})^{100})^{10} = (1 - \frac{1}{100})^{1000}$

在至少一颗卫星被至少选中1次后概率  $1 - (1 - \frac{1}{100})^{1000}$

2.3.2 任意一特征单不被选中的概率  $\frac{C_{19}^{10}}{C_{20}^{10}}$

任意一特征被选中的概率  $1 - \frac{C_9^{10}}{C_{20}^{10}}$

整个过程在特征空间中1次随概率  $1 - \left(\frac{C_0^0}{C_0^0}\right)^{10}$

3.1

1. 令  $f_0(\mathbf{x}) = 0$ 。
2. For  $t=1$  to  $T$ :
  - (a) 计算在各个数据点上的梯度  $\mathbf{g}_t = \left( \frac{\partial}{\partial \mathbf{y}_i} \ell(\mathbf{y}_i, \hat{\mathbf{y}}_i) \right)_{\hat{\mathbf{y}}_i = f_{t-1}(\mathbf{x}_i)}^n$ 。
  - (b) 根据  $-\mathbf{g}_t$  拟合一个回归模型,  $h_t = \arg \min_{h \in \mathcal{F}} \sum_{i=1}^n \ell(y_i, f_{t-1}(\mathbf{x}_i) + \alpha_t h(\mathbf{x}_i))$ 。
  - (c) 选择合适的步长  $\alpha_t$ , 最简单的选择是固定步长  $\eta \in (0, 1]$ 。
  - (d) 更新模型,  $f_t(\mathbf{x}) = f_{t-1}(\mathbf{x}) + \eta g_t$ 。

请完成以下题目:

1. 完成上述算法中的填空 (5pt)。

3.2 
$$g_t = \left( \frac{\partial}{\partial \hat{y}_i} \frac{1}{2} (y_i - \hat{y}_i)^2 \right)_{\hat{y}_i = f_{t-1}(\mathbf{x}_i)}^n$$

$$= -(y_i - f_{t-1}(\mathbf{x}_i))_{i=1}^n$$

$$h_t = (y_i - f_{t-1}(\mathbf{x}_i))_{i=1}^n$$

3.3 
$$g_t = \left( \frac{\partial}{\partial \hat{y}_i} \ln(1 + e^{-y_i \hat{y}_i}) \right)_{\hat{y}_i = f_{t-1}(\mathbf{x}_i)}^n$$

$$= -\left( \frac{y_i e^{-y_i f_{t-1}(\mathbf{x}_i)}}{1 + e^{-y_i f_{t-1}(\mathbf{x}_i)}} \right)_{i=1}^n = \left( -\frac{y_i}{1 + e^{y_i f_{t-1}(\mathbf{x}_i)}} \right)_{i=1}^n$$

$$h_t = \left( \frac{y_i}{1 + e^{y_i f_{t-1}(\mathbf{x}_i)}} \right)_{i=1}^n$$

3.6 在  $L_2$  loss 和 logistic loss 的二分类问题中, 弱学习器数量对分类结果影响不大,

总体上 logistic loss 处理该分类问题更准确


在回归问题上, 发现弱学习器发挥很大作用, 数量越多越准确。

4.3 发现选取树的数量为100, 深度为10, 特征数量为10比较好


4.2 & 4.4

深度越深树越长, 深度为10时, 准确率较大 (0.84705)


深度=5



深度=10



深度=15



4.5 通过调整学习步长  $\{0.01, 0.1, 0.5\}$  与树深度  $\{5, 10\}$

发现步长 0.1, 深度 10 时准确率较高